

AULA 09



Aula 9

Inconsistência de Representação

O Problema: Fragmentação de Categorias



```
1  ID_Cliente, Nome, Cidade, Estado, Fidelidade
2  1, Joao Silva, Sao Paulo, SP, Ouro
3  2, Maria Souza, SÃO PAULO, sp, Prata
4  3, Pedro Lima, Rio Janeiro, RJ, Bronze
5  4, Ana Paula, rio de janeiro, rj, Ouro
6  5, Lucas Dias, B. Horizonte, MG, Prata
7  6, Carla Melo, Belo Horizonte, Minas Gerais, Ouro
8  7, Beto Cruz, Curitiba, PR, Bronze
9  8, Julia Lins, curitiba, parana, Prata
10 9, Tiago Abrav, S. Paulo, S.P., Ouro
11 10, Fernanda M., Sampa, SP, Bronze
```

O sistema trata cada variação como um estado diferente, gerando estatísticas erradas.

Inconsistência de Texto

É a falta de padronização na escrita de valores categóricos, causada geralmente por preenchimento manual.

- **Diferença entre Maiúsculas/Minúsculas**
- **Acentuação e caracteres especiais**
- **Espaços extras invisíveis**
- **Uso de siglas vs nomes completos**

Solução: A Tríade da Limpeza

Aplicamos três passos sequenciais para garantir a unicidade dos dados:

1. Remover espaços (strip) → 2. Padronizar caixa (upper) → 3. Mapear variações (replace)

```
1 # Passos 1 e 2
2 df_limpo['Estado'] = df_limpo['Estado'].str.strip().str.upper()
3
4 # Passo 3 - Dicionário de mapeamento baseado nos dados
5 mapeamento = {
6     'MINAS GERAIS': 'MG',
7     'PARANA': 'PR',
8     'CEARA': 'CE',
9     'PERNAMBUCO': 'PE',
10    'BAHIA': 'BA',
11    'S.P.': 'SP'
12 }
13
14 df_limpo['Estado'] = df_limpo['Estado'].replace(mapeamento)
```


Demonstração