

AULA 10



Aula 10

Outliers (Valores Atípicos)

O Problema: Valores Impossíveis



```
1  Pet_ID, Especie, Idade_Anos, Peso_KG, Ultima_Vacina
2  P01, Cachorro, 5, 12.5, 2023
3  P02, Gato, 3, 4.2, 2024
4  P03, Cachorro, 99, 25.0, 2022
5  P04, Hamster, 1, 0.2, 2024
6  P05, Cachorro, 4, -5.0, 2023
7  P06, Gato, 2, 3.8, 2024
8  P07, Papagaio, 40, 1.2, 2023
9  P08, Cachorro, 2, 800.0, 2024
10 P09, Gato, 15, 5.0, 2021
11 P10, Cachorro, 6, 15.0, 2023
```

Esses valores "puxam" a média para cima ou para baixo, invalidando qualquer análise estatística.

O que são Outliers?

São observações que se afastam drasticamente do padrão da amostra.

- **Impossíveis:** Erros de lógica (ex: peso negativo).
- **Extremos:** Valores muito distantes da maioria (ex: 800kg).

Distorcem a média, o desvio padrão e o comportamento de algoritmos preditivos.

Solução: Identificação com IQR

O método do Intervalo Interquartil (IQR) define limites matemáticos objetivos:

```
1  # Identificacao estatistica com IQR
2  q1 = df['Peso_KG'].quantile(0.25)
3  q3 = df['Peso_KG'].quantile(0.75)
4  iqr = q3 - q1
5
6  limite_inferior = q1 - 1.5 * iqr
7  limite_superior = q3 + 1.5 * iqr
8
9  outliers_iqr = df[(df['Peso_KG'] < limite_inferior) | (df['Peso_KG'] > limite_superior)].copy()
```

Valores fora da faixa [limite_inf, limite_sup] são candidatos a remoção ou investigação.

Demonstração